

Proteiny jsou makromolekuly nezbytné pro všechny živé organismy. Proteinové jazykové modely (PLM) trénované na sekvencích proteinů se v bioinformatice používají k predikci vlastností proteinů nebo ke generování nových proteinů. Vnitřní fungování těchto velkých neuronových sítí však není dobře prozkoumáno. V této práci navazujeme na projekt InterPLM, který k interpretaci příznaků maskovaného PLM využívá řídké autoenkodéry. Tento přístup rozšiřujeme na generativní PLM a porovnáváme interpretovatelnost jeho příznaků s příznaky maskovaného modelu. Práce zavádí nové metody analýzy příznaků, demonstruje jejich praktickou využitelnost a rozšiřuje interaktivní webovou aplikaci pro prozkoumávání příznaků podle konceptu nebo proteinu zájmu. Získané příznaky nakonec využíváme k řízení chování modelu při generování. Toho dosahujeme fixací aktivací vybraných příznaků tak, aby generované proteinové sekvence měly požadované vlastnosti. Analýza výsledků ukazuje, že takový kauzální zásah je u generativního proteinového jazykového modelu možný, což dokládáme generováním neuspořádaných proteinů a tranzitních peptidů.